

Avaliação do Modelo **TabPFN-2.5**

Projeto Final AM 2026-1

Grupo: Laíse Magalhães • Maurício Sightman • Pedro Manoel

Prof. Leandro Maciel Almeida

| Introdução

Limitações

XGBoost
LightGBM
CatBoost

- Engenharia de atributos
- HPO extensivo
- Alto custo computacional

**Busca de novas
abordagens**

ETAPA 1

Fundamentação Teórica

| Modelo Atribuído: TabPFN-2.5



Capacidade de Dados

Suporte a datasets de até 50.000 amostras e 2.000 colunas.



In-Context Learning

Inferência sem necessidade de treinamento específico por tarefa.



SOTA Instantâneo

- Resultados competitivos com AutoML em frações de segundo
- Elimina meses de otimização de hiperparâmetros

| Arquitetura e Formulação

- Baseia-se no conceito de Prior-Data Fitted Networks (PFNs).
- Dado um conjunto de treinamento e uma instância de teste a distribuição preditiva posterior pode ser expressa por:



$$p(y_{test}|x_{test}, D_{train}) = \int_{\Phi} p(y_{test}|x_{test}, \phi)p(\phi|D_{train})d\phi$$

O TabPFN utiliza uma rede neural treinada para aproximar diretamente a distribuição, durante o pré-treinamento é exposto a uma grande quantidade de conjuntos de dados sintéticos gerados a partir de uma distribuição prévia projetada para reproduzir diferentes padrões encontrados em problemas tabulares e o O treinamento é realizado minimizando a função de perda:

$$\mathcal{L}_{PFN} = E_{D \sim p(D)} \left[- \sum_{i \in D_{test}} \log q_{\theta}(y_i|x_i, D_{train}) \right]$$

| Arquitetura e Formulação


- Utiliza uma rede baseada em Transformers




| Arquitetura e Formulação

a

TabPFN is trained on synthetic data to take entire datasets as inputs and predict in a forward pass



TabPFN can now be applied to arbitrary unseen real-world datasets




b

Input dataset

	x_1	x_2	y
Training rows	1.2	6.1	3.0
	8.9	9.1	3.1
	1.0	2.9	6.7
Test	33.3	2.2	?

We predict this entry


2D TabPFN layer (12×)



Each node represents one entry in the table

Predictions: $\hat{y}_{\text{test}}$

The vector is transformed to a piece-wise constant (Riemann) distribution with an MLP



| Complexidade computacional

Durante a inferência, o modelo recebe:

- Conjunto de treinamento (n exemplos);
- conjunto de teste (m exemplos).

Comparação com GBDTs

- XGBoost, LightGBM e CatBoost possuem custo elevado durante o treinamento.
- O TabPFN praticamente elimina o custo de treinamento local (em compensação realiza uma inferência mais sofisticada baseada em atenção).

Por isso o TabPFN costuma ser extremamente competitivo em datasets pequenos e médios, onde o termo n^2 ainda é administrável.

Parte 1: Autoatenção no conjunto de treinamento

$$\mathcal{O}(n^2)$$

Parte 2: Atenção das amostras de teste para o conjunto de treinamento

$$\mathcal{O}(n \cdot m)$$

Complexidade total:

$$\mathcal{O}(n^2 + n \cdot m)$$

| Posicionamento na literatura tabular SOTA

Tabular Foundation Models: Transfere o conhecimento necessário para uma etapa de pré-treinamento com o objetivo de resolver uma ampla variedade de tarefas tabulares.

Desempenho Competitivo: Pois não precisa de treinamento nem tuning extensivo; possui rapidez e simplicidade operacional.

| Hiperparâmetros

Diferentemente dos GBDTs, o TabPFN-2.5 **não requer uma etapa de otimização local de hiperparâmetros**. Seus parâmetros são definidos durante o pré-treinamento e permanecem fixos durante a inferência. Dessa forma, não foi necessário definir um espaço de busca para o Optuna, sendo utilizadas as configurações padrão recomendadas pelos autores.

ETAPA 2

Estudo Experimental

| Metodologia e Baselines

Base de dados: 30 datasets do benchmark TabArena-v0.1

Regimes:

- Pequeno (<1000 amostras)
- Médio (1000-10000 amostras)
- Grande (>10000 amostras)

Procedimento:

- Divisão treino/teste: 70/30
- Seed fixa para reprodutibilidade
- Pré-processamento padronizado

Análise estatística:

- Friedman + Nemenyi/Holm
- Análise Bayesiana (ROPE)

Modelos avaliados:

- TabPFN-2.5
- LightGBM
- CatBoost
- XGBoost
- AutoGluon 1.4 (Default e Extreme)

Métricas:

- ROC-AUC OvO
- Accuracy
- G-Mean
- Cross-Entropy
- Tempo de execução

| Resultados Gerais

Média e desvio padrão para todas as métricas estabelecidas no protocolo do projeto

Sistema	AUC OvO $\uparrow$	ACC $\uparrow$	G-Mean $\uparrow$	Cross-Ent. $\downarrow$	Tempo (s) $\downarrow$
TabPFN-2.5	$0,872 \pm 0,097$	$0,872 \pm 0,089$	$0,663 \pm 0,291$	$0,297 \pm 0,171$	$529,60 \pm 981,83$
LightGBM	$0,853 \pm 0,104$	$0,857 \pm 0,094$	$0,617 \pm 0,290$	$0,336 \pm 0,171$	$0,65 \pm 0,36$
CatBoost	$0,852 \pm 0,100$	$0,859 \pm 0,090$	$0,644 \pm 0,250$	$0,384 \pm 0,208$	$2,70 \pm 1,11$
XGBoost	$0,849 \pm 0,103$	$0,858 \pm 0,092$	$0,620 \pm 0,290$	$0,423 \pm 0,328$	$3,11 \pm 4,07$
AutoGluon default	$0,866 \pm 0,096$	$0,866 \pm 0,092$	$0,640 \pm 0,297$	$0,313 \pm 0,167$	$140,19 \pm 189,24$
AutoGluon extreme 4h	$0,867 \pm 0,094$	$0,866 \pm 0,090$	$0,631 \pm 0,292$	$0,311 \pm 0,169$	$1720,26 \pm 1504,63$

| Resultados: Análise por regime – Tamanho do Dataset

Desempenho (AUC OvO) particionado por tamanho do conjunto de dados (Média $\pm$ Desvio Padrão).

Modelo	Pequeno ($n = 3$)	Médio ($n = 19$)	Grande ($n = 8$)
TabPFN-2.5	0,869 $\pm$ 0,122	0,882 $\pm$ 0,101	0,849 $\pm$ 0,086
LightGBM	0,869 $\pm$ 0,117	0,859 $\pm$ 0,110	0,834 $\pm$ 0,093
CatBoost	0,843 $\pm$ 0,149	0,860 $\pm$ 0,102	0,836 $\pm$ 0,090
XGBoost	0,846 $\pm$ 0,139	0,856 $\pm$ 0,107	0,833 $\pm$ 0,092
AutoGluon default	0,863 $\pm$ 0,126	0,876 $\pm$ 0,099	0,843 $\pm$ 0,089
AutoGluon extreme	0,870 $\pm$ 0,120	0,876 $\pm$ 0,097	0,843 $\pm$ 0,089

| Resultados: Análise por regime – Número de Classes

Desempenho (AUC OvO) estratificado por complexidade do vetor alvo (Média $\pm$ Desvio Padrão).

Modelo	Binário ($n = 24$)	Multiclasse ($n = 6$)
TabPFN-2.5	0,861 $\pm$ 0,088	0,914 $\pm$ 0,129
LightGBM	0,843 $\pm$ 0,096	0,895 $\pm$ 0,131
CatBoost	0,839 $\pm$ 0,094	0,905 $\pm$ 0,116
XGBoost	0,837 $\pm$ 0,092	0,898 $\pm$ 0,136
AutoGluon default	0,856 $\pm$ 0,086	0,908 $\pm$ 0,129
AutoGluon extreme	0,856 $\pm$ 0,086	0,910 $\pm$ 0,122

| Resultados: Análise por Proporção de Features Categóricas

Desempenho (AUC OvO) em função da cardinalidade do espaço de características (Média $\pm$ Desvio Padrão).


Modelo	Alta incidência ($n = 15$)	Baixa incidência ($n = 15$)
TabPFN-2.5	0,868 $\pm$ 0,102	0,875 $\pm$ 0,095
LightGBM	0,854 $\pm$ 0,108	0,852 $\pm$ 0,103
CatBoost	0,855 $\pm$ 0,100	0,849 $\pm$ 0,104
XGBoost	0,850 $\pm$ 0,109	0,848 $\pm$ 0,100
AutoGluon default	0,862 $\pm$ 0,102	0,870 $\pm$ 0,093
AutoGluon extreme	0,863 $\pm$ 0,100	0,870 $\pm$ 0,092

| Resultados: Análise por Presença de Valores Ausentes

Desempenho (AUC OvO) perante a integridade da matriz de dados (Média $\pm$ Desvio Padrão).

Modelo	Sem Valores Ausentes ($n = 24$)	Com Valores Ausentes ($n = 6$)
TabPFN-2.5	0,883 $\pm$ 0,092	0,828 $\pm$ 0,113
LightGBM	0,865 $\pm$ 0,102	0,808 $\pm$ 0,107
CatBoost	0,864 $\pm$ 0,100	0,804 $\pm$ 0,094
XGBoost	0,863 $\pm$ 0,100	0,792 $\pm$ 0,101
AutoGluon default	0,879 $\pm$ 0,092	0,814 $\pm$ 0,103
AutoGluon extreme	0,880 $\pm$ 0,091	0,815 $\pm$ 0,099

| Análise estatística



A Figura ilustra os intervalos de confiança de 95% da média. A notável sobreposição visual entre os intervalos do TabPFN-2.5 e das abordagens AutoGluon torna indispensável o uso de testes rigorosos para avaliar a rejeição da hipótese nula.


| Análise Clássica (Ranks e Diferença Crítica)

Estatísticas descritivas e **avaliação de magnitude** do teste não paramétrico
(Resultantes do **teste de Friedman**)

Modelo	Rank Médio ↓	Mediana	MAD	IC Inferior	IC Superior	Tamanho Efeito	Magnitude
TabPFN-2.5	1,47	0,869	0,093	0,821	0,922	−0,226	Pequeno
AutoGluon Extreme	2,60	0,864	0,088	0,818	0,915	−0,178	Negligível
AutoGluon Default	2,77	0,866	0,087	0,816	0,916	−0,170	Negligível
LightGBM	4,43	0,849	0,087	0,800	0,907	−0,041	Negligível
CatBoost	4,63	0,853	0,096	0,800	0,904	−0,030	Negligível
XGBoost	5,10	0,861	0,091	0,796	0,902	0,000	Negligível

| Análise Clássica (Ranks e Diferença Crítica)

Diagrama de **Diferença Crítica** derivado da análise **post-hoc** de Nemenyi.



As Barras horizontais agrupam modelos cujas diferenças não são estatisticamente significativas ($\alpha = 0,05$).

| Análise Bayesiana e Equivalência Prática (ROPE)

Matriz completa de **probabilidades Bayesianas** par a par com margem **ROPE**.

Modelo A	Modelo B	$P(A < B)$	$P(A \approx B)$	$P(A > B)$
AutoGluon Default	AutoGluon Extreme	0,000	1,000	0,000
AutoGluon Default	CatBoost	0,818	0,183	0,000
AutoGluon Default	TabPFN-2.5	0,000	0,991	0,009
AutoGluon Default	LightGBM	0,283	0,717	0,000
AutoGluon Default	XGBoost	0,988	0,012	0,000
AutoGluon Extreme	CatBoost	0,761	0,239	0,000
AutoGluon Extreme	TabPFN-2.5	0,000	0,992	0,008
AutoGluon Extreme	LightGBM	0,347	0,653	0,000
AutoGluon Extreme	XGBoost	0,962	0,038	0,000
CatBoost	TabPFN-2.5	0,000	0,003	0,997
CatBoost	LightGBM	0,031	0,926	0,043
CatBoost	XGBoost	0,005	0,995	0,000
TabPFN-2.5	LightGBM	0,938	0,062	0,000
TabPFN-2.5	XGBoost	1,000	0,000	0,000
LightGBM	XGBoost	0,111	0,883	0,006

| Discussão dos resultados

Baselines (GBDTs)

- Menor custo computacional
- Tempos médios entre 0,65 e 3,11 s
- Menor desempenho preditivo

AutoGluon Extreme

- Melhor desempenho médio
- Maior custo computacional
- Tempo médio: 1.720 s

TabPFN-2.5

- Desempenho próximo ao AutoGluon Extreme
- Tempo médio: 530 s
- Aproximadamente 69% menos tempo que o AutoGluon Extreme

Principais Conclusões

- Mais preciso que os baselines tradicionais
- Mais eficiente que o AutoML mais custoso
- Melhor relação entre desempenho e custo computacional

O TabPFN-2.5 mostrou-se uma alternativa eficiente para classificação tabular, combinando alto desempenho preditivo com baixa necessidade de ajuste manual.